# FOUNDATIONS OF NATURAL LANGUAGE UNDERSTANDING

自然語言理解的基礎

#### 張家瑋博士

國立臺中科技大學資訊工程系專案助理教授國立成功大學工程科學系兼任助理教授

# FINTECH PROJECT CREDIT RISK

## 徵審系統資料來源



客戶提供之資料 (財報、基本資料)

成立於1975年·是國內唯一的跨金融機構間信用報告機構·同時蒐集個人與企業信用報告建置全國信用資料庫·以提供信用紀錄及營運財務資訊予



經濟部 商業司網站 徴審 系統

財團法人 聯合徵信中心



經濟部商業司為中華民國經濟部的業務單位之一,主管 商業事務及公司登記等



台灣經濟新報 資料庫(TEJ) 台灣經濟研究院 資料庫



台灣經濟新報 (TEJ) 成立於1990年 4月· 專門提供金融市場基 本分析所需的資訊 1976年設立·為台灣最早由民間設立 之獨立學術研究機構。成立之宗旨在 積極從事國內、外經濟及產業經濟之 研究·並將研究成果提供政府、企業 及學術界參考·以促進我國經濟發展

# Credit Risk Framework



#### 永豐金用AI分析授信的風險管理 準確度已達9成

₹ 分享

□ 留言

🖶 列印

ႍ 存新聞

A- A+

2017-11-16 13:01 聯合報 記者林良齊/即時報導

▲ 讃 30 分字

成功大學台北辦公室過去成立30年、年久失修,今年5月與<u>永豐金控</u>簽定合作意象書後,永豐金揭贈經費協助修繕辦公室,今天舉辦啟用典禮,成大研發長謝孫源說,過去的產學、研發重鎮都在台南,希望透過台北辦公室啟用把觸角擴展至台北,深化產學合作。


成功大學校長蘇慧貞表示,成大陸續啟用包括在<u>馬來西亞</u>、越南、印尼等地中心,甚至在非洲馬達加斯加也有,預計明年也啟動歐洲的中心,但「台北反而是距離比較遠」,基地的開發宣誓要盡的社會責任不同。

蘇慧貞也說,成大將會秉持著為未來勾勒、讓民眾享受大數據年代的幸福,未來每個人到成大的每一個空間,都會有新數據的蒐集。

謝孫源指出,<mark>業界十分缺乏AI人才,因此成大也與永豐金合作,讓老師為他們上課</mark>,也期 待未來在金融科技、區塊鏈技術後能夠與他們持續合作,包括客戶端的使用或金融端的風 險管理等都是未來的使用範疇。

永豐金控營運長江威娜指出,目前透過初步的人工智慧分析授信的風險管理準確度已達9成,比起過去單純用統計模型的7成高了不少,未來能夠運用在中小企業的授信上,除了風險管理外,未來也會針對資產配置、壞帳警示等研究,希望能夠透過與成大合作加速上路。 https://udn.com/news/story/7239/2822145

# SEMANTIC SIMILARITY MEASURES



# VECTOR REPRESENTATION

	$W_1$	W <sub>2</sub>	<b>W</b> <sub>3</sub>	••	••	••	W <sub>n-1</sub>	W <sub>n</sub>	label
$D_1$	0.11	0.23	0		••		0.57	0	0
$D_2$	0	0	0				0.29	0.7	1
$D_3$	0	0.81	0.44				0	0	0
$D_4$	0	0.37	0	••	••	••	0	0.16	1
	••	<b>0</b>    <b>0</b>	••	••		••	••	••	
$D_k$	••	••	••	••	••	••	••	••	1

Machine learning

# TF-IDF

### TF-IDF

• TF: term frequency:

$$ext{tf}_{ ext{i,j}} = rac{n_{i,j}}{\sum_k n_{k,j}}$$

IDF: inverse document frequency:

$$ext{idf}_{ ext{i}} = \log rac{|D|}{|\{j: t_i \in d_j\}|}$$

#### where:

- |D|: total number of documents in the corpus
- $|\{j:t_i\in d_j\}|$  : number of documents where term  $\mathsf{t}_i$  appears

#### Then:

 $tfidf_{i,j} = tf_{i,j} \times idf_i$ 

**Document 1** 

Term	Term Count
this	1
is	1
а	2
sample	1

**Document 2** 

Term	Term Count
this	1
is	1
another	2
example	3

The calculation of tf—idf for the term "this" is performed as follows:

$$\mathrm{tf}("\mathsf{this}",d_1) = rac{1}{5} = 0.2 \ \mathrm{tf}("\mathsf{this}",d_2) = rac{1}{7} pprox 0.14$$

$$\operatorname{idf}("\mathsf{this}",D) = \log\!\left(rac{2}{2}
ight) = 0$$

 So tf-idf is zero for the word "this", which implies that the word is not very informative as it appears in all documents.

$$ext{tfidf}(" ext{this}",d_1)=0.2 imes0=0 \ ext{tfidf}(" ext{this}",d_2)=0.14 imes0=0$$

**Document 1** 

Term	Term Count
this	1
is	1
а	2
sample	1

**Document 2** 

Term	Term Count
this	1
is	1
another	2
example	3


 A slightly more interesting example arises from the word "example", which occurs three times only in the second document:


$$\mathrm{tf}(''\mathsf{example}'',d_1) = rac{0}{5} = 0 \ \mathrm{tf}(''\mathsf{example}'',d_2) = rac{3}{7} pprox 0.429$$

$$\operatorname{idf}("\mathsf{example}",D) = \log\!\left(rac{2}{1}
ight) = 0.301$$

$$ext{tfidf}("\mathsf{example}",d_1) = ext{tf}("\mathsf{example}",d_1) imes ext{idf}("\mathsf{example}",D) = 0 imes 0.301 = 0$$
  $ext{tfidf}("\mathsf{example}",d_2) = ext{tf}("\mathsf{example}",d_2) imes ext{idf}("\mathsf{example}",D) = 0.429 imes 0.301 imes 0.13$ 


# WORD2VEC







## **One Hot Encoding**

```
The -> [0. 1. 0. 0. 0. 0. 0. 0. 0. 0.]
cat -> [0. 0. 1. 0. 0. 0. 0. 0. 0. 0.]
jump -> [0. 0. 0. 1. 0. 0. 0. 0. 0. 0.]
over -> [0. 0. 0. 0. 1. 0. 0. 0. 0. 0.]
the -> [0. 0. 0. 0. 1. 0. 0. 0.]
dog \rightarrow [0. 0. 0. 0. 0. 0. 1. 0. 0. 0.]
The -> [0. 1. 0. 0. 0. 0. 0. 0. 0. 0.]
dog \rightarrow [0. 0. 0. 0. 0. 1. 0. 0. 0.]
ate -> [0. 0. 0. 0. 0. 0. 1. 0. 0.]
my \rightarrow [0. 0. 0. 0. 0. 0. 0. 0. 1. 0.]
homework -> [0. 0. 0. 0. 0. 0. 0. 0. 1.]
```



- Features:  $x = (x_1, x_2)$
- Target: y = +1 or -1
- $h(x) = w_0 + w_1 x_1 + w_2 x_2$






$$h(x) = w_0 + w_1 x_1 + w_2 x_2$$


$$scores = \sum_{i}^{N} w_i x_i + b$$

$$scores = \sum_{i}^{N+1} w_i x_i$$


- 若  $scores \ge 0$  , 则  $\hat{y} = 1$
- 若 scores < 0 , 则  $\hat{y} = -1$



[Case 1] y = 1 錯分成 y = -1





[Case 2] y = -1 錯分成 y = 1




[Case 1] y = 1 錯分成 y = -1

[Case 2] y = -1 錯分成 y = 1







# Multi-Layer Perceptron (MLP)



### PLA



## MLP



The -> [0. 1. 0. 0. 0. 0. 0. 0. 0. 0.]

cat -> [0. 0. 1. 0. 0. 0. 0. 0. 0. 0. 0.]

jump -> [0. 0. 0. 1. 0. 0. 0. 0. 0. 0.]

over -> [0. 0. 0. 0. 1. 0. 0. 0. 0. 0.]

the -> [0. 0. 0. 0. 0. 1. 0. 0. 0. 0.]

dog -> [0. 0. 0. 0. 0. 0. 1. 0. 0. 0.]

The -> [0. 1. 0. 0. 0. 0. 0. 0. 0. 0. 0.]

ate -> [0. 0. 0. 0. 0. 0. 0. 1. 0. 0.]

my -> [0. 0. 0. 0. 0. 0. 0. 1. 0. 0.]

homework -> [0. 0. 0. 0. 0. 0. 0. 0. 1. 0.]

